Волгоградский государственный университет
Институт математики и информационных технологий
Кафедра информационных систем и компьютерного моделирования

Работа допущена к защите
Заведующий кафедрой

_____ А. В. Хоперсков

«____» _____ 2022 г.

Бут Александр Андреевич

Использование классификаторов в машинном обучении

Отчет по учебной практике, научно-исследовательской работе (получение первичных навыков научно-исследовательской работы)

Направление: 09.03.04 – Программная инженерия

Студент группы ПРИб-201:
А. А. Бут _____ подпись

Руководитель практики:
С. С. Хохлова, к.ф.-м.н., доцент каф. ИСКМ _____ подпись

Ответственный за организацию практики:
М. А. Корнаухова, ст. преподаватель каф. ИСКМ _____ подпись

Волгоград — 2022

Содержание

Введение

Машинное обучение – одна из самых перспективных областей современной индустрии информационных технологий. Алгоритмы данной сферы программирования способны решать многие задачи, которые человек либо не способен решить, либо хочет оптимизировать и автоматизировать. Компьютерное мышление в настоящие дни внедряется во многих процессах – от таргетированной комерческой рекламы до прогнозирования прогрес сирования раковых опухолей в медицине. Позволяя решать подобные задачи вычислительной технике, общество извлекает из всего этого пользу, несоизмеримо высокую, в сравнении с собственными затраченными ресурсами. Проводя аналогии, обучение искусственного интеллекта на примере многообразия схожих задач напоминает прогресс общества, когда поколение от поколения люди перенимали знания и опыт предков и передавали потомкам, однако протекающий в гораздо более краткие сроки.

Актуальность данной тематики изучения основ и применения на практике классификаторов машинного обучения заключается в том, что достижение определенных целей с помощью машинного обучения возможно огромным количеством разных путей. Именно избрание наиболее подхо дящего в определенной ситуации, предварительно изучив всю специфику и сферы применения каждого из них является ключом к эффективному решению какой бы то ни было задачи.

Обратимся к более профилированному примеру. Возможность по набору определенных личных предпочтений предсказать направление подготовки при обучении в вузе, определяющее вектор развития для человека, как минимум на последующие четыре года, а зачастую и на значительно более длительный период – означает избавление от личных переживаний, мук выбора, а в глобальном плане – более корректное распределение ресурсов внутри страны, когда грамотные специалисты будут изначально утверждены на позиции,

на которых может быть максимально раскрыт их потенциал.

Целью работы является сравнительный анализ результатов работы нескольких классификаторов для решения задач анализа данных. Задачи:

1. Сбор и изучение литературы по теме исследования.

2. Рассмотрение линейных моделей для классификации данных.

3. Провести сравнительный анализ результатов работы нескольких классификаторов для решения задач анализа данных.

Глава 1

Теория машинного обучения

1.1 Выбор языка программирования

Язык, выбираемый для разработки в сфере искусственного интеллекта и машнного обучения, должен соответствовать нескольким очевидным критериям [1] – быть гибким, стабильным и содержать расширенный спектр инструментов, в том числе, для работы с большим объемом данных.

Язык программирования Python, выбранный для данной научно-исследовательской работы, избирается в настоящее время большим числом специалистов для создания ИИ-систем, этим же широким сообществом пользователей в полной мере поддерживается и дорабатывается, в связи с чем, машинное обучение стало одной из основных отраслей специализации данного языка. Он содержит обширный стек библиотек:

- Keras, TensorFlow, и Scikit-learn – непосредственно для машинного обучения;
- NumPy – для вычислений научного характера;
- SciPy – для вычислений более высокого уровня;
- Pandas – для анализа данных;
- Seaborn – для их визуализации;

В то же время, Python лаконичен и прост в освоении, что позволяет, практически без трат времени на освоение синтаксиса, сразу же акцентировать внимание именно на разработке систем и общей структуре отдельных библиотек.

Таким образом, используя язык программирования Python, можно через минимальный промежуток времени преодолеть порог вхождения при понимании лингвистической специфики, технических аспектов и сосредоточиться на

изучении отдельных алгоритмов, что, как раз, и требуется новичку, желающему начать изучать машинное обучение.

1.2 Общие теоретические сведения о машинном обучении

Машинное обучение – категория алгоритмов, позволяющая программам предсказывать результаты без явного программирования [2]. Возникло оно в 60-х годах прошлого века, когда исследователи были заинтересованы в создании искусственного интеллекта. Практически сразу от подобных систем требовалось обучение на данных. К этой проблеме пытались подойти с помощью различных методов [3]. Алгоритмы машинного обучения делятся на обучение с учителем и без. Для первого необходимо предоставить качственные данные для ввода, желаемый результат, а также наладить обратную связь о точности предсказаний. Два основных метода обучения с учителем:

- Классификация.

Группировка объектов по заранее установленным признакам, самые популярные методы классификации – алгоритм «наивного Байеса» и метод опорных векторов.

- Регрессия.

Применяется, когда нужно спрогнозировать результат и записывается в виде уравнения взаимосвязи входных и выходных данных. Часто используемые алгритмы -= линейная, полиномиальная и логистическая регрессия.

При обучении без учителя осуществляется поиск взаимосвязей между объектами входных данных, когда полноценного однозначного ответа на выходе не требуется. Основные методы:

- Кластеризация.

При кластеризации происходит деление входных данных на группы по признаку, который система выделяет сама при их анализе. Наиболее распростра-

ненные методы – DBSCAN и метод K-средних, применяемые, к примеру, в работе с изображениями. [4]

- Снижение размерности.

Используется для оптимизации скорости и расходования памяти другими методами ML, когда работа ведется с многомерными данными, сложными для визуализации и восприятия, чтобы обобщить все признаки до уровня выше. Примеры - алгоритм T-NSE, сингулярное разложение.

- Нейронные сети.

Нейронные сети - особая математическая модель, применяемая в машинном обучении, построенная по аналогии с работой нейронов в человеческом мозге [5].

1.2.1 Персептрон

Математическая модель нейронной сети, состоящего из одного нейрона, который выполняет две последовательные операции [6]:

- вычисляет сумму входных сигналов с учетом их весов (проводимости или сопротивления) связи:

$$sum = \vec{X^T}\vec{W} + \vec{B} = \sum_{i=1}^{n} x_i w_i + b; \tag{1.1}$$

- применяет активационную функцию к общей сумме воздействия входных сигналов.

1.3 Построение классификатора для обработки данных

Построение классификатора сложено из нескольких шагов [7].

1. Подготовка данных.

Изучается предметная область, касаемо которой будет вестись работа, составляется база данных из характерных ей объектов.

2. Предобработка данных.

Включает в себя отбор значимых для классификации признаков, трансформацию и очистку данных (исключение дубликатов, противоречивых или ошибочных экземпляров, нормализацию). Результат – получение оптимальной базы примеров, однозначно разделяемой на классы.

3. Разделение.

Весь набор данных делится на два множества: обучающее и тестовое (в отдельных случаях допускается использование третьего, валидационного, множества.)

4. Выбор системы кодирования выходных данных. Примеры видов систем:

- «2 на 2»-кодирование;
- классическое;

5. Конструирование, обучение и анализ результатов. При конструировании выбирается топология сети, функции нейронов и т.д. Затем оценить качество работоспособности алгоритма на тестовой выборке. Убедиться в достижении необходимой точности и результативности. В случае несоответствия вернуться на предыдущий этап и изменить параметры.

1.4 Теоретические сведения о матрице корреляций

Матрица корреляций - особый объект, представленный в виде ограниченной двумя координатными осями таблицы значений. Используется для подведения итогов классификации и определения ее точности. Внутри сетки значений расположены верно и неверно предсказанные объекты классов [8].

В качестве примера рассмотрим матрицу корреляций, получаемую в результаты работы одного из алгоритмов, который будет описан ниже. На приведенном рисунке (см. рисунок 1.1) число в верхнем левом квадрате обозначает количество объектов, принадлежность к классу для которых определена

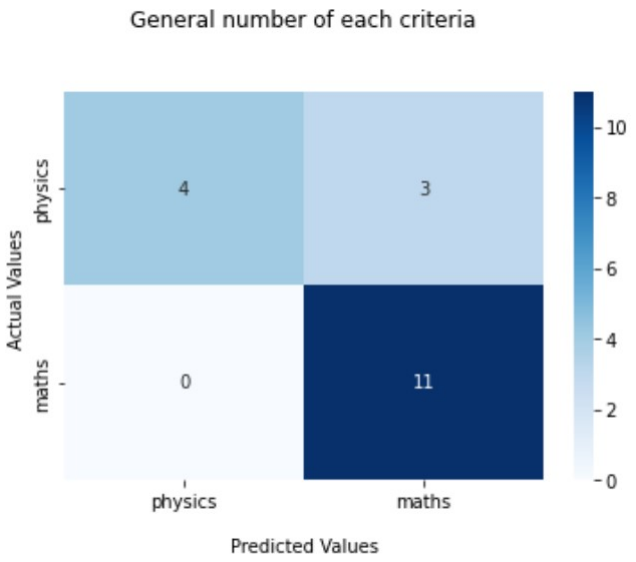

Рисунок 1.1. Матрица корреляций

верно, в правом – неверно. Для второго класса число в нижнем левом квадрате обозначает количество объектов, для которых класс определен неверно, в правом - верно.

1.5 Чувствительность, специфичность и эффективность алгортимов линейной классификации

Существуют особые величины для оценки работы алгоритма, вычисляемые на основании матрицы корреляций [9].

- чувствительность – отношение правильных предсказаний для объектов первого класса к общему количеству предсказаний этого класса.

- специфичность – отношение правильных предсказанний для объектов второго класса к общему количеству предсказаний этого класса.

- эффективность – квадратный корень из произведения чувствительности и специфичности.

Глава 2

Классификаторы машинного обучения

Рассмотрим алгоритмы классификации, применённые в данной работе.

2.1 Метод ближайших соседей для решения задачи классификации

Алгоритм устроен следующим образом. У нас есть тренировочная выборка, мы запоминаем ее объекты, и когда нам поступает новый объект – мы осуществляем поиск наиболее похожих на него объектов выборки среди ближайших к нему и смотрим, какой ответ доминирует – 0/1 и выдадим этот класс в качестве ответа. Другими словами, поступивший объект определяется как доминирующий класс среди объектов, более всего на него похожих. Для определения ближайших к объекту соседей предусмотрены различные метрики, выбирающиеся как параметр [10]:

- Евклидова метрика:

$$\rho(x, y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2}. \tag{2.1}$$

- Расстояние Чебышева:

$$\rho(x, y) = \max_{i=1,..,n} |x_i - y_i| \tag{2.2}$$

- Манхэттенское Расстояние:

$$\rho(x, y) = \sum_{i=1}^{n} |x_i - y_i|. \tag{2.3}$$

Поскольку наши данные изначально имеют одинаковую физическую природу, а, следовательно, и удельный вес – выборка с помощью евклидового расстояния подходит нам более чем. Число рассматриваемых соседей

выбирается самостоятельно и является гиперпараметром алгоритма. Метод ближайших соседей максимально толерантен к резким границам между классами, т.е. способен предугадывать принадлежность нового объекта к определенному классу с минимальным участием границы, это происходит в связи с тем, что он оперирует максимальным локальным максимальным правдоподобием. Отсюда и проблемы: точность очень сильно зависит от числа соседей, например, если взять все элементы за выборку – метод просто переобучится и возьмет за вероятность долю элементов.

2.2 Использование наивного байесовского классификатора для линейной классификации

Одна из самых простых моделей для решения задач классификации, однако в некоторых простых задачах способна давать достаточно точные и качественные результаты. Например, в задаче фильтрации спам-писем, практически все алгоритмы работают на основе байесовского.

Томас Байес ввёл понятие вероятности наступления определенного события x, при условии, что событие y уже случилось [11]:

$$P(x|y) = \frac{P(x,y)}{P(y)} \tag{2.4}$$

Из данного соотношения была выведена другая формула:

$$P(x,y) = P(x|y)P(y) = P(y|x)P(x) \tag{2.5}$$

Вероятность наступления события x получается путем умножения вероятности наступления события y на вероятность наступления события x, при условии, что y случилось. Отсюда возник финальный вид формулы Байеса:

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)} \tag{2.6}$$

Таким образом, для каждого объекта высчитывается данная вероятность, определяющая, насколько возможна принадлежность нового объекта к тому или иному классу.

2.3 Использование деревьев решений для линейной классификации

Один из самых старых алгоритмов, но до сих пор достаточно популярный. Симулирует процесс, который ранее принимали люди. Например, в прошлом, сотрудник банка задавал клиенту, желающему взять кредит, вопросы, в зависимости от ответа на каждый из которых, выбирался следующий вопрос, исходя из чего принималось решение предоставить займ или нет.

Алгоритм автоматизирует процесс, система учитывает исторические данные прецедентов, работает со всеми предоставленными параметрами по объекту, например, вернувшись к примеру выше, ей были бы предоставлены данные об уровне дохода, наличии постоянной работы и т.д. Затем, она находит по каким данным можно сепарировать объекты на множества. Существует два подхода к делению объектов на группы:

- Метод максимизации энтропии
- Метод хи-квадрата

Машина сама будет выбирать один из признаков, расщеплять данные и приходить к решению. Решения принимается с некоторой вероятностью, чем она выше – тем лучше точность предсказания.

Достоинства классификатора, выделяющие его на фоне остальных [12]:

- Интерпретируемость и наглядность
- Производительность

Недостаток классификатора, из-за которого метод не применим для больших объемов данных:

- Сложность контроля размера дерева

Алгоритм относится к числу «жадных» – то есть допускающих, что локальные решения на каждом шаге приводят к оптимальному результату. В частности, для деревьев решений это означает, что если на каком-либо шаге по определенному атрибуту уже произошло разделение, повернуть назад и выбрать другой нельзя. Потому невозможно изначально сказать как на итоговый результат повлияет тот или иной атрибут.

Дерево решений представляет собой древовидную структуру из внутренних и внешних вершин и соединяющих их ребер. Внутренние узлы рассчитывают значение функции решения, на основании которого определяется узел для дальнейшего посещения. Внешние характеризуют входные данные и не имеют дочерних узлов. Таким образом, весь алгоритм состоит в следующем:

- Передаются данные на корневой узел дерева.

- В зависимости от полученного значения осуществляется переход к дочернему узлу.

- Переходы продолжаются до тех пор, пока не будет достигнут конечный узел с меткой класса.

В основе обучения деревьев решений лежит принцип «разделяй и властвуй» [13].

2.4 Алгоритм логистической регрессии для линейной классификации

Алгоритм является подвидом множественной регрессии. Выходная характеристика объекта может быть:

- Категориальной.

- Бинарной (избираться из множества, содержащего два значения).

Во втором виде выходной переменной объект может принадлежать определенному классу на выходе – А или Б, каждый из исходов является соответствующим событием. После сравнения вероятностей событий, получается

результат, являющийся меткой класса (А или Б), вероятность принадлежности к которому выше (см. рисунок 2.1).

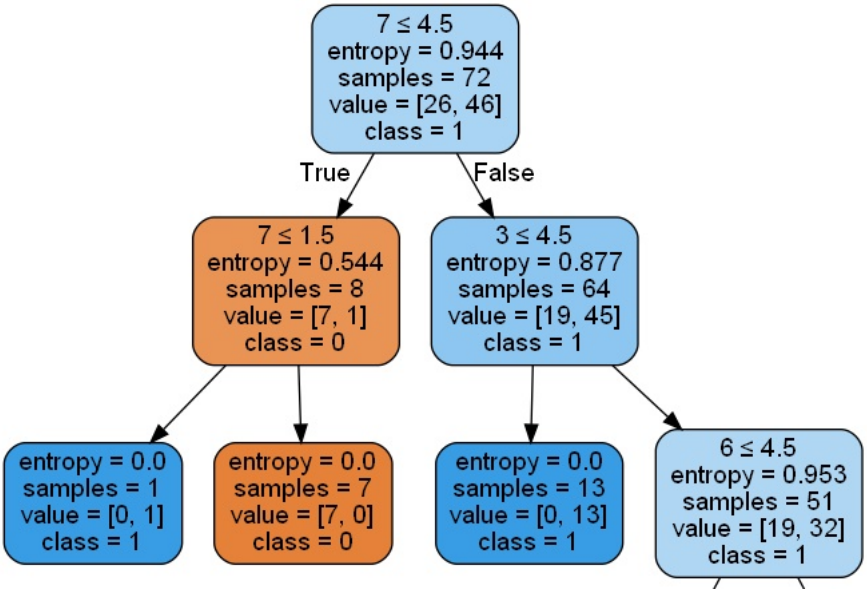

Рисунок 2.1. Кадр дерева решений из программы

Преимущество метода – наличие ROC-анализа для определения качества моделей.

2.5 Алгоритм лучайного леса для линейной классификации

В основе лежит построение ансамбля деревьев решений, каждое из которых строится путём выборки с возвращением (бутстрепа) [14], примененного к исходной. Число таких деревьев – гиперпараметр и может быть выбрано самостоятельно. Отличия от простого построения дерева решений:

- используется константное число определенных признаков;
- строится полное дерево, а не усеченное;
- оценка регрессии и классификация на основе выводов по всем деревьям;

Общий алгоритм можно представить в следующем виде:

Для каждого из деревьев

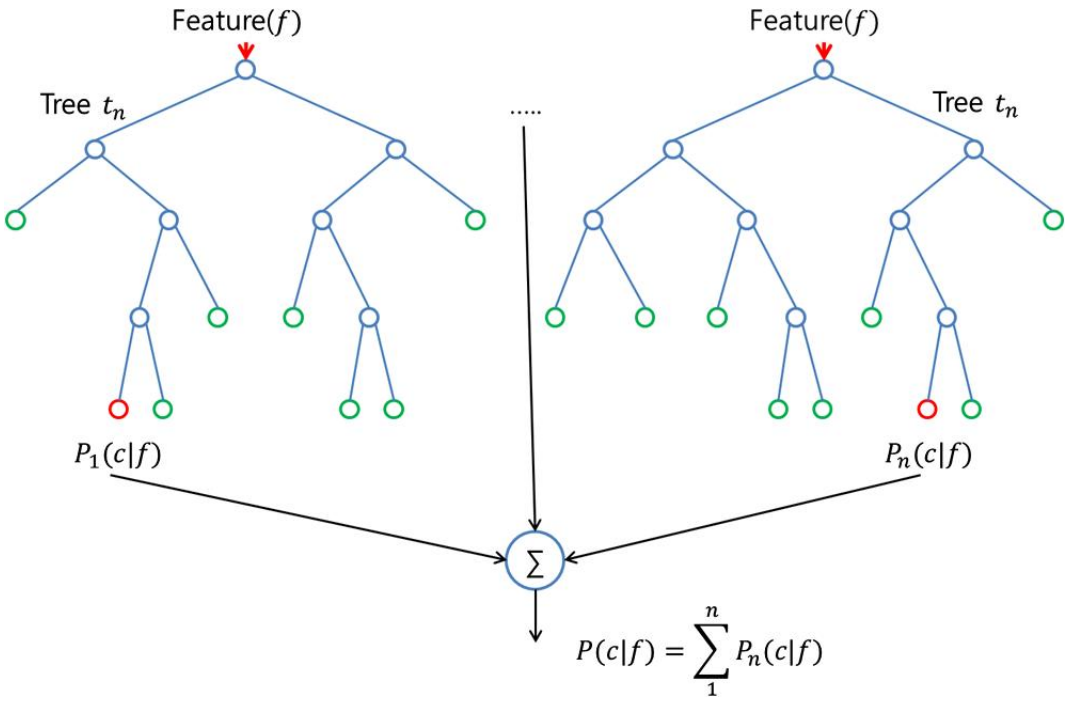

Рисунок 2.2. Пример ансамбля деревьев [15]

1. формируется бутстреп выборка исходной;
2. индуцируется неусеченное дерево по следующему подалгоиртму:
   a) из n признаков выбирается случайно p признаков;
   b) из p выбирается обеспечивающий оптимальное расщепление;
   c) выборка расщепляется на две;
3. в результате получается ансамбль деревьев решений, по которому осуществляется предсказание.

Достоинства метода, выделяющие его на фоне других:

- Нет необходимости в тестовой выборке для оценки точности.

- Проблема усечения дерева, свойственная обычному методу деревьев решений отсутствует.

- Нет проблемы отбора признаков, свойственной другим методам с большим количеством деревьев.

- Простота применения.

- Возможность параллельных вычислений.

2.6 Метод опорных векторов для линейной классификации

Главная задача метода – оптимальным путем разделить предоставленный набор данных [11]. Пространство между двумя ближайшими точками называется зазором [16]. Необходимо расположить гиперплоскость с максимально возможным зазором между опорными векторами. Поиск такой гиперплоскости осуществляется по следующему алгоритму:

1. Генерируются возможные гиперплоскости, делящие набор данных с каким-либо зазором.

2. Из них выбирается такая, что при делении зазор максимален.

Некоторые задачи нельзя решить с помощью линейной гиперплоскости. В такой ситуации используется ядерный трюк для преобразования входного пространства в пространство более высокого измерения. Таким образом, входные данные просто преобразуются в вид, пригодный для разделения по вышеописанному алгоритму. Виды так называемых «ядерных трюков»:

- Линейное ядро.
- Полиномиальное ядро.
- Ядро радиальной базисной функции.

Глава 3

Проведение линейной классификации и сравнительного анализа методов

3.1 Работа с базой данных для последующего корректного обучения алгоритмов

3.1.1 Выполнение начальной одготовки данных

Для исследования была выбрана база данных, которая состоит из результатов опроса первокурсников, поступивших в 2021 году, и у которых уже сложилось некоторое мнение об обучении в университете на их собственной специальности (см. рисунок 3.1).

	A	B	C	D	E
1	Отметка времени	1. ФИО	2. Ваше направление обучения (полное название)	3. Сумма результатов трёх ЕГЭ	4. Часто ли вы проводите время за компьютером?
2	11.30.2021 11:52:20	Устарханов Артём Уллубиевич	МОС		213
3	12.1.2021 15:17:08	Зенченко Егор Андреевич	МОС		168
4	12.10.2021 19:28:14	Васильев Максим Сергеевич	ПМФ		164
5	11.28.2021 12:03:27	Гувалов Руслан Гумбатович	ИСТ		190
6	11.30.2021 11:09:09	Устиновская Марина Андреевна	ПРИ		264
7	11.30.2021 13:15:15	Горбаченко Юлия Анатольевна	МОС		181
8	11.28.2021 12:17:52	Панафидин Михаил Николаевич	ИСТ		219
9	11.28.2021 12:21:19	Омельченко Олеся	ПРИ		225
10	11.30.2021 11:43:07	Олейник Алина Александровна	МОС		204
11	11.30.2021 13:00:24	Зверяев Виталий Михайлович	МОС		246
12	11.30.2021 13:08:13	Пономарев Александр Сергеевич	МОС		240
13	11.30.2021 13:21:32	Савельев Андрей Леонидович	МОС		196
14	12.10.2021 18:01:30	Мыльников Иван Николаевич	ПМФ		211
15	11.28.2021 11:05:45	Лиджиев Владимир Мингиянович	ИСТ		220
16	11.28.2021 12:02:00	Фролова Юлия Алексеевна	ИСТ		265
17	11.28.2021 12:50:10	Агапченко Олег Андреевич	ИСТ		199
18	11.30.2021 11:10:03	Резанов Кирилл Владимирович	ПРИ		238
19	11.30.2021 11:13:55	Астахов Данила Александрович	ПРИ		210
20	11.30.2021 16:18:16	Ракчеев Никита Сергеевич	ПРИ		246
21	11.30.2021 11:43:36	Чернышов Олег Сергеевич	МОС		222
22	11.30.2021 11:45:47	Крайнев Никита Евгеньевич	МОС		224
23	11.30.2021 11:51:01	Макарова Елена Вячеславовна	МОС		222
24	11.30.2021 11:59:42	Кутняшенко Кирилл Дмитриевич	МОС		210
25	11.30.2021 12:15:17	Баркова Анастасия Юрьевна	МОС		265
26	11.30.2021 13:00:58	Ляпина Ксения Александровна	МОС		198
27	12.1.2021 15:18:54	Керимов Артур Рустамович	МОС		174
28	12.10.2021 17:03:51	Сивкаев Артём Аланович	ПМФ		188
29	12.10.2021 17:08:24	Романов Даниил Игоревич	ПМФ		175
30	11.28.2021 11:20:02	Косомов Александр Сергеевич	ИСТ		207
31	11.30.2021 11:09:54	Утянок Анастасия Сергеевна	ПРИ		256
32	11.30.2021 13:13:12	Живолупов Вадим Дмитриевич	МОС		182
33	12.1.2021 16:40:56	Звездин Антон Валентинович	МОС		208
34	12.1.2021 17:11:18	Карюков Климент Владимирович	МОС		235
35	11.30.2021 11:20:39	Шепелев Матвей Игоревич	ПРИ		230
36	11.30.2021 11:27:58	Кукса Виталий Константинович	ПРИ		228
37	11.30.2021 11:50:06	Попова Анастасия Дмитриевна	МОС		259
38	11.30.2021 11:53:22	Гуреенкова Милана Владиславовна	МОС		202

Рисунок 3.1. Кадр excel-документа базы данных

3.1.2 Предобработка данных с целью исключения некорректных для обучения данных

Для привлечения прохождения опроса были привлечены следующие группы обучающихся с первого курса института математики и информационных технологий: программная инженерия, информационные

системы и технологии, математическое обеспечение и администрирование информационных систем, прикладная математика и физика, радиотехника, радиофизика, математика и компьютерные науки, прикладная математика и информатика, информатика и вычислительная техника, прикладная информатика, прикладная математика и информатика. Одним из самых важных шагов при построении классификатора является предобработка данных. На этом этапе изучается перечень объектов базы с их характеристиками и основываясь на общих умозаключениях, сделанных на шаге подготовки, проводится работа по удалению несоответствующих общей логике элементов. Другими словами, мы смотрим на базу данных, ее свойства и предопределяем, каким образом тот или иной ее объект повлияет на обучение системы. Если сразу понятно, что элемент в той или иной степени помешает алгоритму вывести общую закономерность – он исключается. Назовем такой элемент ненадежным, поскольку он потенциально может обучить систему неправильно.

Идеальный результат, к которому должна прийти система в этой работе – исходя из ответов на анкетирование с максимальной точностью определять на какую специальность поступил человек. Если объект из базы будет содержать противоречия, к примеру, в вопросе «Нравится ли вам физика?» респондент выставил баллов меньше, чем в вопросе «Нравится ли вам математика?», но при этом поступил на физическую специальность (Радиофизика, Прикладная математика и физика) – он внесет свой вклад в обучение системы неправильным образом, в соответствии с этими противоречивыми данными. Точно также, анкетируемые с низкими баллами могут повлиять не на обучение должным образом, поскольку часть из них поступала с доминирующим влиянием не собственных предпочтений, а сложившихся обстоятельств. И наконец, были исключены данные, содержащие в тех же вопросах про симпатию к отдельным школьным предметам одинаковые баллы, поскольку данные элементы содержат не перевес в одну из сторон, а пятидесятипроцентную

вероятность (см. рисунок 3.2).

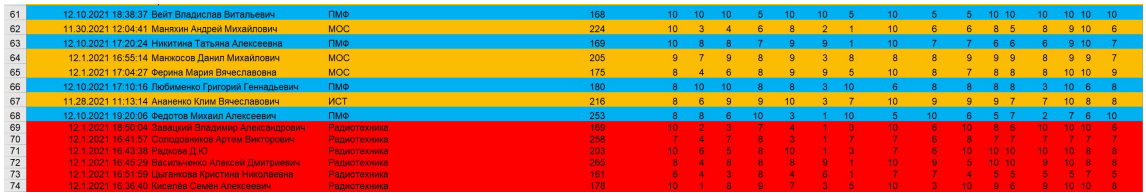

61	12.10.2021 18:38:37	Вейт Владислав Витальевич	ПМФ	168	10	10	10	5	10	10	5	10	5	5	10	10	10	10	10	10
62	11.30.2021 12:04:41	Манякин Андрей Михайлович	МОС	224	10	3	4	6	8	2	1	10	6	6	8	5	8	9	10	6
63	12.10.2021 17:20:24	Никитина Татьяна Алексеевна	ПМФ	169	10	8	8	7	9	9	1	10	7	7	6	6	6	9	10	7
64	12.1.2021 16:55:14	Манкосов Данил Михайлович	МОС	205	9	7	9	8	9	3	8	8	8	9	9	9	8	9	9	7
65	12.1.2021 17:04:27	Ферина Мария Вячеславовна	МОС	175	8	4	6	8	9	9	5	10	8	7	8	8	8	10	10	9
66	12.10.2021 17:10:16	Любименко Григорий Геннадьевич	ПМФ	180	8	10	10	8	8	3	10	6	8	8	8	8	3	10	6	8
67	11.28.2021 11:13:14	Ананенко Клим Вячеславович	ИСТ	216	8	6	9	9	10	3	7	10	9	9	9	7	7	10	8	8
68	12.10.2021 19:20:06	Федотов Михаил Алексеевич	ПМФ	253	8	8	6	10	3	1	10	5	10	6	6	7	2	7	6	10
69	12.1.2021 18:50:04	Завацкий Владимир Александрович	Радиотехника	169	10	2	3	7	4	1	3	10	6	10	8	6	10	10	10	6
70	12.1.2021 16:41:57	Солодовников Артем Викторович	Радиотехника	258	7	4	7	8	3	1	7	7	6	8	7	7	7	7	7	7
71	12.1.2021 16:43:38	Радкова Д.Ю	Радиотехника	203	10	6	5	8	10	1	3	7	6	10	10	10	10	10	8	8
72	12.1.2021 16:45:29	Васильченко Алексей Дмитриевич	Радиотехника	265	8	4	8	8	8	9	1	10	9	5	10	10	9	10	8	8
73	12.1.2021 16:51:59	Цыганкова Кристина Николаевна	Радиотехника	161	6	4	3	8	4	6	1	7	7	4	5	5	5	5	7	5
74	12.1.2021 16:36:40	Киселев Семен Алексеевич	Радиотехника	178	10	1	8	9	7	3	5	10	3	10	9	6	9	10	10	8

Рисунок 3.2. Кадр excel-документа обработанной базы данных

Таким образом, в изначальной базе с 91 абитуриентом их осталось 63. База подготовлена к загрузке в систему. Обучим систему и на изначальной базе, и на отредактированной.

3.2 Разработка приложения для линейной классификации и проведения сравнительного анализа методов

3.2.1 Изучение синтаксиса подключения библиотек и работы с их основными модулями

Как было сказано выше, язык программирования Python предоставляет широкий инструментарий для машинного обучения, для работы с данными и их графической визуализацией. Рассмотрим библиотеки, которые были подключены и использовались в данной работе.

- pandas.

Библиотека и непосредственно ее функция read_exel() использовалась непосредственно для чтения базы Exel объектов.

- sklearn.

Основная библиотека, содержащая классификаторы, такие как KNeighborsClassifier (классификатор ближайших соседей), DecisionTreeClassifier (классификатор деревьев решений), GuassianNB (наивный байесовский классификатор), RandomForestClassifier (классификатор случайного леса),

LogisticRegression (логистическая регрессия) и svm, в частности класс SVC (метод опорных векторов). Также содержит оператор confusion_matrix(), на основании параметров y_true и y_pred (каноничный и предсказанный результаты) вычисляющий матрицу запутанности, показывающую, насколько метод точен и оператор train_test_split(), осуществляющий деление входных данных на тестовую выборку и обучающую.

Для визуализации результирующего графа метода деревьев решений эта библиотека содержит функцию export_graphviz().

- seaborn.

Функция heatmap модуля seaborn использовалась для создания цветной матрицы запутанности.

- matplotlib.

Функция plt.show() использовалась для вывода отрисованной с помощью heatmap-функции матрицы на экран.

3.2.2 Написание программного кода

Процесс написания программы был начат с подключения основных библиотек для прочтения exel-файла с данными, функции которых были описаны выше (см. листинг 3.1).

Листинг 3.1. Подключение библиотек

```
1 import math
2 import pandas as pd
3 import numpy as np
4 import seaborn as sns
```

Далее были прочитаны и, для проверки корректности чтения, были выведены на экран данные файла (см. листинг 3.2).

Листинг 3.2. Чтение exel-файла

```
1 df = pd.read_excel('preliminary.xlsm')
2 print(df)
```

Были созданы необходимые для работы переменные, такие как переменная количества итераций, матрица для результатов работы всех алгоритмов, массив, содержащий ответы студентов на каждый из вопросов (для последующей постройки по нему графика размаха), в который соответствующие данные были сразу записаны (см. листинг 3.3).

Листинг 3.3. Задание глобальных переменных

```
n = 5000
characteristic_table = [[['KNN'], [0],[0],[0]],
                        [['DT'], [0],[0],[0]],
                        [['NB'], [0],[0],[0]],
                        [['RF'], [0],[0],[0]],
                        [['LR'], [0],[0],[0]],
                        [['SVC'], [0],[0],[0]]]
method_id = 0
every_question_base = []
j = 0
for i in range (4, 34):
    every_question_base.append(np.array(df.iloc[:, i]))
    print(every_question_base[j])
    print('\n')
    j+1
```

Отдельно была проведена работа по подключению библиотек, а затем созданию алгоритма, отрисовывающего матрицу запутанности в цвете. В нем графику был задан цвет градиента, подписаны оси (см. листинг 3.4).

Листинг 3.4. Создание алгоритма для матрицы запутанности

```
from sklearn.metrics import confusion_matrix
import matplotlib.pyplot as plt

def confusion_matrix_visualization(cm):
    matrix = sns.heatmap(cm, annot=True, cmap='Blues')

```

```
7     matrix.set_title('General number of each criteria\n\n')
8     matrix.set_xlabel('\nPredicted Values')
9     matrix.set_ylabel('Actual Values ')
10
11    matrix.xaxis.set_ticklabels(['physics','maths'])
12    matrix.yaxis.set_ticklabels(['physics','maths'])
13
14    plt.show(matrix)
```

Далее была начата работа по написанию алгоритмов, работающих непосредственно с выходными данными, на результате работы которых строится вся данная исследовательская работа. Функция «acc» (accuracy) - на основании матрицы запутанности (cm) подсчитывает точность классификатора. Аналогично «sens» (sensitivity), «spec» (specifity) и «effect» (effectivity) - подсчитывают чувствительность, специфичность и эффективность алгоритмов соответственно. Функция «count_values» вызывает каждую из перечисленных последовательно и записывает результаты в массив, который и возвращает (см. листинг 3.5).

Листинг 3.5. Написание функций

```
1 def acc(cm):
2     total=sum(sum(cm))
3     accuracy=(cm[0,0]+cm[1,1])/total
4     return accuracy
5
6 def sens(cm):
7     sensitivity = cm[0,0]/(cm[0,0]+cm[0,1])
8     return sensitivity
9
10 def spec(cm):
11    specificity = cm[1,1]/(cm[1,0]+cm[1,1])
12    return specificity
13
14 def effect(cm):
```

```
15     effectivity = math.sqrt(sens(cm)*spec(cm))
16     return effectivity
17
18
19 def count_values(true, predicted):
20     cm = confusion_matrix(true, predicted)
21     print("ACCURACY: ", acc(cm))
22     values = [0, 0, 0]
23     values[0] = sens(cm)
24     values[1] = spec(cm)
25     values[2] = effect(cm)
26     return (values)
```

Следующим шагом, была проведена настройка входных данных, переменным «x» и «y» были переданы соответственно массив ответов студентов на вопросы и результирующий класс, к которому каждый студент относится. Здесь же был подключен модуль train_test_split, необходимый, как было описано выше, для разделения входных данных на тестовую и обучающую выборку (см. листинг 3.6).

Листинг 3.6. Предварительное разделение входной группы по переменным

```
1 x = df.values[:, 4:32]
2 x=x.astype('int')
3 y = df.values[:, 34]
4 y=y.astype('int')
5 print(x)
6 print(y)
7 from sklearn.model_selection import train_test_split
```

После всех перечисленных выше шагов входные данные были приведены в необходимый вид. Была начата работа непосредственно с классификаторами. Были предприняты следующие шаги для каждого из них:

1. Подключение.
2. Присвоение классификатору уникального идентификатора, необходи-

мого в последующем для вывода его результирующих значений.

3. Создание локальных массивов результирующих значений.

4. Задание критериев классификатора.

5. В цикле на 5000 итераций в процессе каждой из них

a) входная группа делилась на тестовую и обучающую выборку в соотношении 20% к 80%;

b) классификатор обучался на обучающей выборке;

c) предсказывался результат для тестовой выборки;

d) фиксировалась чувствительность, специфичность и эффективность;

Далее, уже вне цикла

6. Выводились на экран средние чувствительность, специфичность и эффективность.

7. Эти же параметры записывались в общую характеристическую таблицу.

На листинге 3.7 представлена часть программы, в которой велась работа с одним из классификаторов

Листинг 3.7. Работа с классификатором ближайших соседей

```
1 from sklearn.neighbors import KNeighborsClassifier
2 method_id = 0
3 values = [0, 0, 0]
4 sensitivity = []
5 specifity = []
6 effectivity = []
7 knn = KNeighborsClassifier(n_neighbors=9, weights="uniform",
    metric="euclidean")
8 for i in range(0, n):
9     x_train, x_test, y_train, y_test = train_test_split(x, y,
        test_size=0.20, stratify=y)
10     knn.fit(x_train, y_train)
```

```
11      predicted = knn.predict(x_test)
12      values = count_values(y_test, predicted)
13      print(values)
14      sensitivity.append(values[0]), specifity.append(values[1]),
            effectivity.append(values[2])
15  print(np.mean(sensitivity), np.mean(specifity), np.mean(
        effectivity))
16  characteristic_table[method_id][1] = np.mean(sensitivity)
17  characteristic_table[method_id][2] = np.mean(specifity)
18  characteristic_table[method_id][3] = np.mean(effectivity)
```

Отличия синтаксиса программы остальных классификаторов от приведенного заключаются в их номере идентификатора, а также самом названии как классификатора, так и ответственной за его вызов переменной На листингах 3.8, 3.9 и 3.10 представлено подключение классификатора деревьев решений, присвоение переменной типа модуля классификатора деревьев решений и его обучение соответственно.

Листинг 3.8. Подключение классификатора деревьев решений

```
1 from sklearn.tree import DecisionTreeClassifier
```

Листинг 3.9. Присвоение переменной значения модуля классификатора

```
1 dtc = DecisionTreeClassifier(criterion = "entropy", max_depth =
      5)
```

Листинг 3.10. Обучение классификатора

```
1 dtc.fit(x_train, y_train)
```

На основании хода предсказания классификатора деревьев решений был построен полный граф, визуализирующий процесс принятия решения, кадр которого был представлен в главе 2. Для этого использовались модули display.Image библиотеки IPython, StringIO библиотеки six и библиотека pydotplus (см. листинг 3.11).

Листинг 3.11. Построение графа деревьев решений

```
from sklearn.tree import export_graphviz
from six import StringIO
from IPython.display import Image
import pydotplus

answer_cols = df.iloc[-1, 4:32]

dot_data = StringIO()
export_graphviz(dtc, out_file=dot_data, filled=True, rounded =
    True, special_characters=True, feature_names=answer_cols,
    class_names = ['0', '1'])
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
graph.write_png('Students.png')
Image(graph.create_png())
```

И также на основании данных об ответах на вопросы «Нравится ли вам математика?» и «Нравится ли вам физика» были построены графики размаха, визуализирующие распределение ответов на вопросы в зависимости от класса (см. листинг 3.12).

Листинг 3.12. Создание графика с усами

```
for i in range (0 , 2):
    ax = sns.boxplot(x=df.iloc[:, 34], y=every_question_base[i])
    plt.show()
```

Расширенный листинг программы представлен в приложении А (см листинг А.1).

3.3 Результаты

3.3.1 Статистическая обработка базы данных

Рассмотрим графики размаха, получившиеся в конце программы, чтобы проанализировать входные данные.

Была создана визуализация ответов на шесть вопросов, которые нагляднее всего показывают различия между элементами двух разных классов (см. рисунок 3.3). Подписанные буквы обозначают определенный вопрос:

А) Вопрос 7. «Нравится ли вам математика?»

Б) Вопрос 12. «Нравится ли вам физика?»

В) Вопрос 14. «Нравится ли вам разбираться в принципе работы электронных устройств?»

Г) Вопрос 19. «Нравится ли вам решать математические задачи?»

Д) Вопрос 32. «Нравится ли вам паять схемы?»

Е) Вопрос 6. «Нравится ли вам решать головоломки?»

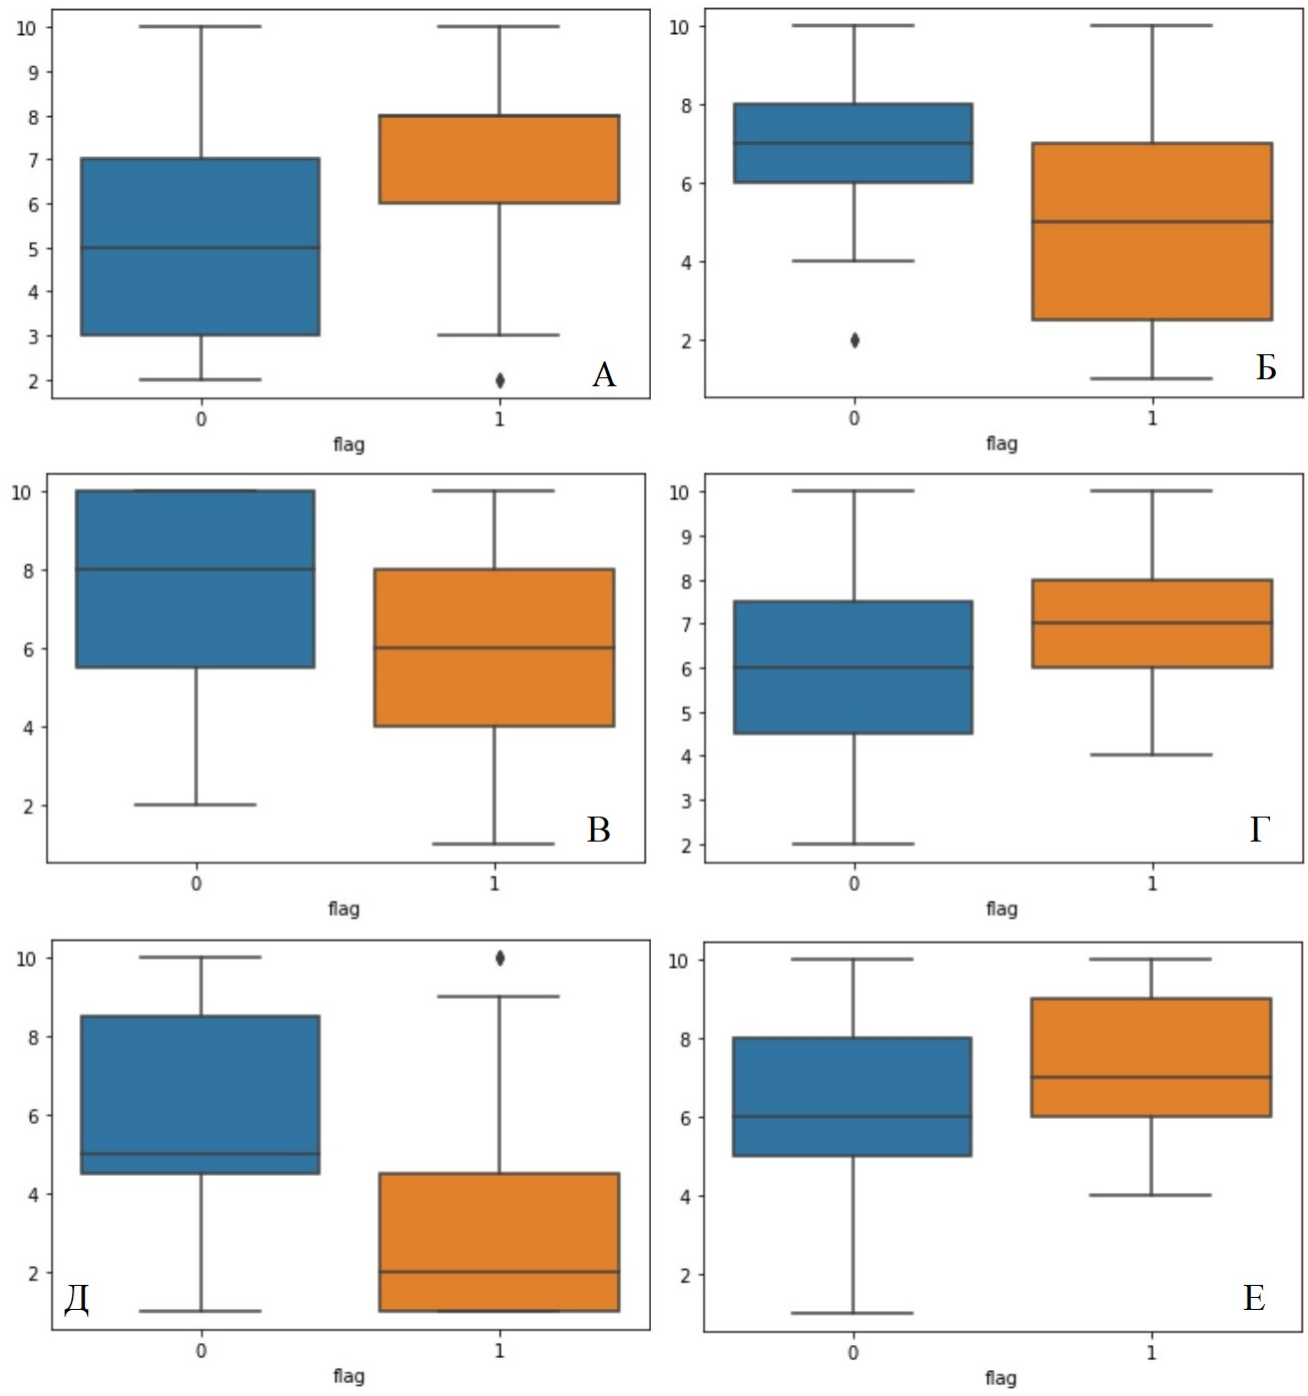

Рисунок 3.3. Графики распределения ответов для шести вопросов

3.3.2 Общие выводы

1. Наиболее оптимально сказаться на обучении должны были вопросы А, Б и Д, поскольку область схожести ответов на них минимальна.

2. Вопросы В, Г и Е сказались на обучении негативным образом, поскольку в них существовала высокая схожесть ответов между представителя-

ми двух классов.

3. Ответы студентов, отстоящие от общей массы ответов респондентов (артефакты), сказались на обучении негативно, поскольку потенциально могут обучить систему воспринимать подобные нестандартные ответы как определяющие для того или иного класса.

3.3.3 Результаты сравнительного анализа классификаторов, получаемого в ходе работы программы

На выходе получилась таблица 3.1 значений чувствительности, специфичности и эффективности.

Таблица 3.1. Сравнительный анализ методов классификации, завершивших работу с полной базой студентов

	KNN	DT	RF	NB	LOGREG	SV
чувствительность	0,2998	0,6268	0,3185	0,7142	0,5428	0,5664
специфичность	0,7107	0,8737	0,7808	0,7272	0,7763	0,7146
эффективность	0,4269	0,7322	0,4647	0,7207	0,6295	0,6210

3.3.4 Выводы на основании таблицы

1. Сравнив строки «чувствительность» и «специфичность» можно прийти к выводу, что класс «1» всеми алгоритмами предсказывается с большей точностью, чем класс «0».

2. Эффективнее всего сработали алгоритмы деревьев решений и наивного Байеса (DT и NB в таблице). Эффективность первого метода составила 0,7322, а эффективность второго – 0,7207, и остальные показатели выше, чем показатели других алгоритмов.

3. Для классификатора деревьев решений, чувствительность которого на выходе 0,6268, а специфичность 0,8737, наличие в базе ненадежных эле-

ментов, большинство из которых относится к классу «0», означает снижение точности определения принадлежности к этому же классу «0», тогда как для классификатора наивного Байеса присутствие этих элементов сказывается в равной степени как на предсказании класса «0», так и на предсказании класса «1», поскольку его чувствительность 0,7142, а специфичность 0,7272.

4. Метод ближайших соседей (KNN в таблице) и метод случайного леса (RF в таблице) хуже, чем другие методы, определяют принадлежность к классу «0». Можно сделать вывод, что они более чувствительны к ненадежным элементам, в частности, к их классу.

Обоснованием подобной точности алгоритмов и общих проблем с отнесением объектов к классу «0» является недостаточное количество элементов этой группы, а также содержание среди них ошибочных. На этапе предобработки данных была проведена работа по исключению несоответствующих требованиям объектов, однако в последствии они были добавлены обратно, и алгоритмы обучались на целостной базе, потому процент ошибочных объектов класса «0» слишком высок и дает слишком высокую погрешность, поскольку классификаторы обучались на частично некорректной базе.

Обучим алгоритмы на базе, из которой исключены ненадежные элементы (выбросы). Результаты представлены в таблице 3.2.

Таблица 3.2. Сравнительный анализ чувствительности, специфичности и эффективности методов классификации, завершивших работу с базой студентов, из которой были исключены ненадежные элементы

	KNN	DT	RF	NB	LOGREG	SV
чувствительность	0,2646	0,4723	0,3262	0,5176	0,5314	0,4003
специфичность	0,7984	0,6298	0,7798	0,6761	0,7672	0,7780
эффективность	0,4136	0,5230	0,4739	0,5770	0,6257	0,4977

3.3.5 Выводы на основании второй таблицы

1. Рассмотрев детально каждую строку, можно прийти к выводу, что заметные изменения произошли с чувствительностью, для метода деревьев решений произошло ее снижение с 0,6268 до 0,4723, для Наивного Байесовского классификатора с 0,7142 до 0,5176, что говорит о повысившейся сложности определения принадлежности к классу «0».

2. Произошло недообучение в силу недостаточного наличия элементов класса «0» в базе.

3. Часть алгоритмов (случайный лес, логистическая регрессия, метод опорных векторов) выдала схожие с первыми результаты.

4. Наивный Байесовский классификатор и метод деревьев решений на выходе оказались более чувствительными к качеству входной группы данных.

3.3.6 Общие выводы на основании двух результирующих таблиц

1. Все методы хорошо справляются с классификацией объектов класса «1».

2. Объекты класса «0» характеризуются хуже.

3. Достигнутая после двух запусков программы эффективность показывает, что алгоритм деревьев решений и алгоритм наивного Байеса способны осуществлять поиск закономерностей даже среди неидеальной базы данных, что выделяет их на фоне других и позволяет получить лучшие результаты.

4. Для получения близких к идеальным результатов необходимо, чтобы база данных содержала развернутую информацию о представителях каждого класса, а также большое количество объектов, относящихся к каждому из них.

Заключение

В ходе работы были решены следующие задачи:

1. Были изучены основные положения машинного обучения.

2. Было разобрано несколько классификаторов машинного обучения, их пути развития, определены наиболее результативные для приведенной базы.

3. Был проведен сравнительный анализ результатов работы выбранных классификаторов.

4. На данных из базы классификаторы были обучены определять принадлежность элементов к определенным классам, проведена оценка эффективности для каждого из алгоритмов. Для метода деревьев решений была достигнута эффективность 73%, для алгоритма наивного байеса 72%.

Все цели, поставленные в данной научной работе, выполнены. Общую результативность работы можно оценить на основании следующих компетенций.

В процессе проведения работы с классификаторами были изучены основные понятия теории машинного обучения, был осуществлен поиск информации в научных статьях, после был написан программный код, что соответствует компетенции ОПК-1. «Способен применять естественнонаучные и общеинженерные знания, методы математического анализа и моделирования, теоретического и экспериментального исследования в профессиональной деятельности»

Для работы с методами классификации был установлен интерпретатор языка программирования Python 3.9.7, а также расширение JupiterNotebook для редактора кода Visual Studio Code, что соответствует компетенции ОПК-5. «Способен инсталлировать программное и аппаратное обеспечение для информационных и автоматизированных систем»

После установки необходимого для работы программного обеспечения были изучены и применены его основные инструменты, что соответствует компетенции ОПК-2. «Способен понимать принципы работы современных ин-

формационных технологий и программных средств, в том числе отечественного производства, и использовать их при решении задач профессиональной деятельности».

В процессе работы был произведен поиск информации в литературных базах «Киберленинка», «IEEEXplore», а также в электронных библиотеках «Университетская библиотека ONLINE» и «Лань», что соответствует компетенции ОПК-3. «Способен решать стандартные задачи профессиональной деятельности на основе информационной и библиографической культуры с применением информационно-коммуникационных технологий и с учетом основных требований информационной безопасности».

Отчет по учебной практике оформлен в соответствии с установленными кафедрой ИСКМ требованиями нормконтроля, что соответствует компетенции ОПК-4. «Способен участвовать в разработке стандартов, норм и правил, а также технической документации, связанной с профессиональной деятельностью».

Программа, разработанная в ходе научно-исследовательской работы, способна предсказывать направление подготовки абитуриента на основании его ответов на фиксированный перечень вопросов, а также осуществляет сравнительный анализ различных методов классификации, что соответствует компетенции ОПК-6. «Способен разрабатывать алгоритмы и программы, пригодные для практического использования, применять основы информатики и программирования к проектированию, конструированию и тестированию программных продуктов».

В работе были изучены следующие классификаторы:

- классификатор K-ближайших соседей;
- наивный байесовский классификатор;
- алгоритм деревьев решений;
- алгоритм случайного леса;
- алгоритм логистической регрессии;

- метод опорных векторов;

Их настройка велась на онсновании приобретенных в ходе выполнения работы теоретических сведений, из чего можно сделать вывод о соответствии компетенции ОПК-7. «Способен применять в практической деятельности основные концепции, принципы, теории и факты, связанные с информатикой».

Основным компонентом и хранилищем объектов, на которых обучались классификаторы, являлась база данных абитуриентов 2021 года поступления, информация из которой была загружена и обработана в программе (см. листинг 3.2), что свидетельствует о соответствии компетенции ОПК-8. «Способен осуществлять поиск, хранение, обработку и анализ информации из различных источников и баз данных, представлять ее в требуемом формате с использованием информационных, компьютерных и сетевых технологий».

Список литературы

1. Почему Python — лучший язык для машинного обучения и ИИ / «pythonist.ru». — URL: https://pythonist.ru/pochemu-python-luchshij-yazyk-dlya-mashinnogo-obucheniya-i-ii/ (дата обр. 12 апр. 2022). — Режим доступа: свободный. – Текст: электронный.
2. *Geron A.* Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems. — 2-е изд. — Kalifornia, USA : O'Reilly Media, 2019. — С. 10—21.
3. *Клячкин В. Н., Жуков Д. А.* Прогнозирование состояния технического объекта с прменением методов машинного обучения. // Прикладные продукты и системы. — 2019. — Т. 32, № 2. — С. 1—4.
4. *Berkhin P.* Survey of Clustering Data Mining Techniques // Accrue Software. — Milmont, USA, 2006. — С. 1—15.
5. *Каниа К. А.* Нейронные сети. Эволюция. — 1-е изд. — Москва : ЛитРес, 2020. — С. 1—7.
6. *Вьюгин В. В.* Математические основы теории машинного обучения и прогнозирования. — Москва : МЦМНО, 2013. — С. 10—14.
7. *Rashid T.* Make Your Own Neural Network. — South Carolina : CreateSpace Independent Publishing Platform, 2016. — С. 101—103.
8. *Hackeling G.* Mastering Machine Learning with scikit-learn. — 2-е изд. — Birmingham : PACKT, 2014. — С. 50—56.
9. Evaluating Categorical Models II: Sensitivity and Specificity. / «Towards Data Science.com». — URL: https://towardsdatascience.com/evaluating-categorical-models-ii-sensitivity-and-specificity-e181e573cff8 (дата обр. 29 апр. 2022). — Режим доступа: свободный. – Текст: электронный.

10. *Шашкин А. И.*, *Стрюков Р. К.* О модификации метода ближайших соседей // Вестник Воронежского государственного университета. — Воронеж, 2015. — № 1. — С. 1—7.

11. *Кувайскова Ю. Э.* Статистические методы прогнозирования: Учебное пособие (СЭБ). — Ульяновск : УлГТУ, 2019. — С. 10—15.

12. *Сорокин А. Б.*, *Железняк Л. М.* Технологии обучения кластеризация и классификация: Практикум (СЭБ). — Москва, 2021. — С. 5—10.

13. *Гофман Е. А.*, *Олейник А. А.*, *Субботин С. А.* Кластер-анализ с использованием деревьев решений. // Радиоэлектроника и информатика : науч.-техн. журн. — 2011. — С. 21—25.

14. *Макшанов А. В.*, *Журавлев А. Е.*, *Тындыкарь Л. Н.* Большие данные Big Data: учебник для вузов. — Санкт-Петербург : Лань, 2022. — С. 120—188.

15. Объяснение и настройка параметров алгоритма случайного леса / «russianblogs.com». — URL: `https://russianblogs.com/article/15251109270/` (дата обр. 20 мая 2022). — Режим доступа: свободный. – Текст: электронный.

16. *Лесковец Ю.*, *Раджараман А.*, *Ульма Д. Д.* Анализ больших наборов данных. — Москва : ДМК Пресс, 2016. — С. 225—240.

Приложение А

Листинг программы для сравнительного анализа алгоритмов линейной классификации

Листинг А.1. Пример листинга программы, осуществляющей обучение классификаторов и их сравнение

```
import math
import pandas as pd
import numpy as np
import seaborn as sns
df = pd.read_excel('preliminary.xlsm')
print(df)
n = 5000
characteristic_table = [['KNN'], [0],[0],[0]],
                        ['DT'], [0],[0],[0]],
                        ['NB'], [0],[0],[0]],
                        ['RF'], [0],[0],[0]],
                        ['LR'], [0],[0],[0]],
                        ['SVC'], [0],[0],[0]]]
method_id = 0
every_question_base = []
j = 0
for i in range (4, 34):
    every_question_base.append(np.array(df.iloc[:, i]))
    print(every_question_base[j])
    print('\n')
    j+1

from sklearn.metrics import confusion_matrix
import matplotlib.pyplot as plt

def confusion_matrix_visualization(cm):
```

```
27      matrix = sns.heatmap(cm, annot=True, cmap='Blues')
28
29      matrix.set_title('General number of each criteria\n\n')
30      matrix.set_xlabel('\nPredicted Values')
31      matrix.set_ylabel('Actual Values ')
32
33      matrix.xaxis.set_ticklabels(['physics','maths'])
34      matrix.yaxis.set_ticklabels(['physics','maths'])
35
36      plt.show(matrix)
37
38 def acc(cm):
39      total=sum(sum(cm))
40      accuracy=(cm[0,0]+cm[1,1])/total
41      return accuracy
42
43 def sens(cm):
44      sensitivity = cm[0,0]/(cm[0,0]+cm[0,1])
45      return sensitivity
46
47 def spec(cm):
48      specificity = cm[1,1]/(cm[1,0]+cm[1,1])
49      return specificity
50
51 def effect(cm):
52      effectivity = math.sqrt(sens(cm)*spec(cm))
53      return effectivity
54
55
56 def count_values(true, predicted):
57      cm = confusion_matrix(true, predicted)
58      print("ACCURACY: ", acc(cm))
59      values = [0, 0, 0]
60      values[0] = sens(cm)
61      values[1] = spec(cm)
```

```
62      values[2] = effect(cm)
63      return (values)
64
65 x = df.values[:, 4:32]
66 x=x.astype('int')
67 y = df.values[:, 34]
68 y=y.astype('int')
69 print(x)
70 print(y)
71 from sklearn.model_selection import train_test_split
72
73 from sklearn.neighbors import KNeighborsClassifier
74 method_id = 0
75 values = [0, 0, 0]
76 sensitivity = []
77 specifity = []
78 effectivity = []
79 knn = KNeighborsClassifier(n_neighbors=9, weights="uniform",
       metric="euclidean")
80 for i in range(0, n):
81      x_train, x_test, y_train, y_test = train_test_split(x, y,
           test_size=0.20, stratify=y)
82      knn.fit(x_train, y_train)
83      predicted = knn.predict(x_test)
84      values = count_values(y_test, predicted)
85      print(values)
86      sensitivity.append(values[0]), specifity.append(values[1]),
           effectivity.append(values[2])
87 print(np.mean(sensitivity), np.mean(specifity), np.mean(
       effectivity))
88 characteristic_table[method_id][1] = np.mean(sensitivity)
89 characteristic_table[method_id][2] = np.mean(specifity)
90 characteristic_table[method_id][3] = np.mean(effectivity)
91
92 from sklearn.tree import DecisionTreeClassifier
```

```
dtc = DecisionTreeClassifier(criterion = "entropy", max_depth =
    5)
method_id = 1
values = [0, 0, 0]
sensitivity = []
specifity = []
effectivity = []
for i in range(0, n):
    x_train, x_test, y_train, y_test = train_test_split(x, y,
        test_size=0.20, stratify=y)
    dtc.fit(x_train, y_train)
    predicted = knn.predict(x_test)
    values = count_values(y_test, predicted)
    print(values)
    sensitivity.append(values[0]), specifity.append(values[1]),
        effectivity.append(values[2])
print(np.mean(sensitivity), np.mean(specifity), np.mean(
    effectivity))
characteristic_table[method_id][1] = np.mean(sensitivity)
characteristic_table[method_id][2] = np.mean(specifity)
characteristic_table[method_id][3] = np.mean(effectivity)
sensitivity, specifity, effectivity = 0, 0, 0

from sklearn.tree import export_graphviz
from six import StringIO
from IPython.display import Image
import pydotplus

answer_cols = df.iloc[-1, 4:32]

dot_data = StringIO()
export_graphviz(dtc, out_file=dot_data, filled=True, rounded =
    True, special_characters=True, feature_names=answer_cols,
    class_names = ['0', '1'])
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
```

```
122 graph.write_png('Students.png')
123 Image(graph.create_png())
124
125 from sklearn.naive_bayes import GaussianNB
126 method_id = 2
127 nb = GaussianNB()
128 sensitivity = []
129 specifity = []
130 effectivity = []
131 for i in range(0, n):
132     x_train, x_test, y_train, y_test = train_test_split(x, y,
          test_size=0.20, stratify=y)
133     nb.fit(x_train, y_train)
134     predicted = knn.predict(x_test)
135     values = count_values(y_test, predicted)
136     print(values)
137     sensitivity.append(values[0]), specifity.append(values[1]),
          effectivity.append(values[2])
138 print(np.mean(sensitivity), np.mean(specifity), np.mean(
      effectivity))
139 characteristic_table[method_id][1] = np.mean(sensitivity)
140 characteristic_table[method_id][2] = np.mean(specifity)
141 characteristic_table[method_id][3] = np.mean(effectivity)
142 sensitivity, specifity, effectivity = 0, 0, 0
143
144 from sklearn.ensemble import RandomForestClassifier
145 method_id = 3
146 rf = RandomForestClassifier(n_estimators=100,
147                             bootstrap = True,
148                             max_features = 'sqrt')
149 sensitivity = []
150 specifity = []
151 effectivity = []
152 for i in range(0, n):
153     x_train, x_test, y_train, y_test = train_test_split(x, y,
```

```
            test_size=0.20, stratify=y)
154     rf.fit(x_train, y_train)
155     predicted = rf.predict(x_test)
156     values = count_values(y_test, predicted)
157     print(values)
158     sensitivity.append(values[0]), specifity.append(values[1]),
            effectivity.append(values[2])
159 print(np.mean(sensitivity), np.mean(specifity), np.mean(
      effectivity))
160 characteristic_table[method_id][1] = np.mean(sensitivity)
161 characteristic_table[method_id][2] = np.mean(specifity)
162 characteristic_table[method_id][3] = np.mean(effectivity)
163 sensitivity, specifity, effectivity = 0, 0, 0
164
165 from sklearn.linear_model import LogisticRegression
166 method_id = 4
167 logreg = LogisticRegression()
168 sensitivity = []
169 specifity = []
170 effectivity = []
171 for i in range(0, 50):
172     x_train, x_test, y_train, y_test = train_test_split(x, y,
            test_size=0.20, stratify=y)
173     logreg.fit(x_train, y_train)
174     predicted = logreg.predict(x_test)
175     values = count_values(y_test, predicted)
176     print(values)
177     sensitivity.append(values[0]), specifity.append(values[1]),
            effectivity.append(values[2])
178 print(np.mean(sensitivity), np.mean(specifity), np.mean(
      effectivity))
179 characteristic_table[method_id][1] = np.mean(sensitivity)
180 characteristic_table[method_id][2] = np.mean(specifity)
181 characteristic_table[method_id][3] = np.mean(effectivity)
182 sensitivity, specifity, effectivity = 0, 0, 0
```

```
183
184 from sklearn import svm
185 method_id = 5
186 svc = svm.SVC(kernel='linear')
187 sensitivity = []
188 specifity = []
189 effectivity = []
190 for i in range(0, n):
191     x_train, x_test, y_train, y_test = train_test_split(x, y,
          test_size=0.20, stratify=y)
192     svc.fit(x_train, y_train)
193     predicted = svc.predict(x_test)
194     values = count_values(y_test, predicted)
195     print(values)
196     sensitivity.append(values[0]), specifity.append(values[1]),
          effectivity.append(values[2])
197 print(np.mean(sensitivity), np.mean(specifity), np.mean(
      effectivity))
198 characteristic_table[method_id][1] = np.mean(sensitivity)
199 characteristic_table[method_id][2] = np.mean(specifity)
200 characteristic_table[method_id][3] = np.mean(effectivity)
201 sensitivity, specifity, effectivity = 0, 0, 0
202
203 print(characteristic_table)
204 for j in range(1, 5):
205     for i in range(1, 4):
206         if(j == 1):
207             print('KNN: ', characteristic_table[j][i])
208         if(j == 2):
209             print('DT: ', characteristic_table[j][i])
210         if(j == 3):
211             print('NB: ', characteristic_table[j][i])
212         if(j == 4):
213             print('RF: ', characteristic_table[j][i])
214         if(j == 5):
```

```
215             print('RF: ', characteristic_table[j][i])
216     print(' ')
217
218 fig, ax = plt.subplots()
219 ax.xaxis.set_visible(False)
220 ax.yaxis.set_visible(False)
221 clust_data = characteristic_table
222 collabel=("method", "sensitivity", "specitivity", "effectivity")
223 ax.table(cellText=clust_data,colLabels=collabel,loc='center')
224
225 for i in range (0 , 30):
226     ax = sns.boxplot(x=df.iloc[:, 34], y=every_question_base[i])
227     plt.show()
```